

Exploração, Tratamento e Análise de Dados no Databricks

Design de Dashboards Orientado a Tomada de Decisão — Aula 3

O Fluxo Analítico Profissional: Do Dado Bruto à Decisão

A proposta desta aula é estruturar um fluxo metodológico completo e rigoroso. Não basta apenas criar gráficos; é preciso garantir a qualidade e a relevância de cada informação extraída.

01

Dados Brutos

Compreensão da organização lógica no Databricks, leitura inicial das tabelas.



02

Qualidade

Data Profiling detalhado para investigar nulos, duplicados e inconsistências.



03

Tratamento

SQL analítico estruturado: filtros, ordenações, agrupamentos e CASE WHEN.



04

Indicadores

Derivação de métricas de negócio e cálculo de KPIs (Margem, Ticket Médio).



05

Visualização

Design de gráficos e dashboards orientados a responder perguntas de negócio.

O Ciclo da Decisão: Como Transformar Dados em Lucratividade

Será que qualquer dado pode simplesmente ir para a tela?

DADO

O Registro Frio

"venda = R\$ 3.500"

Um número isolado, cru e sem contexto que por si só não gera direcionamento para o negócio.

INFORMAÇÃO

O Contexto Temporal

"A loja vendeu R\$ 3.500 na terça-feira"

Adiciona contexto (dia, local, operação). Agora sabemos o que aconteceu na operação.

INSIGHT

A Descoberta Prática

"As vendas de terça ficaram 27% abaixo da média"

A análise comparativa revela uma anomalia, uma oportunidade ou um gargalo crítico.

DECISÃO

A Ação Concreta

"Investigar queda e criar ação comercial"

A tomada de atitude baseada em dados reais para reverter o quadro e otimizar resultados.

Arquitetura no Databricks: Entendendo Catalog, Schema e Table

A Estrutura de Três Níveis

- **Catalog (Catálogo):** O nível mais alto de organização de dados. Ele gerencia as permissões de acesso e serve como o contêiner central para todos os dados corporativos.
- **Schema (Esquema/Database):** Funciona como um agrupador lógico de tabelas dentro de um catálogo específico. Facilita o isolamento por projetos, áreas ou fontes.
- **Table (Tabela):** O local onde os dados estruturados realmente residem, organizados estritamente em linhas, colunas tipadas e metadados estruturais.

Regra de ouro: Antes de desenhar qualquer gráfico ou dashboard, conheça a fundo o catálogo, o esquema e as tabelas disponíveis.

Comandos Essenciais de Exploração

Para inspecionar a estrutura física e fazer amostragens lógicas antes do desenvolvimento:

1. Inspecionar Colunas e Tipos:

```
DESCRIBE vendas;
```

2. Visualizar Amostra dos Dados (10 linhas):

```
SELECT * FROM vendas LIMIT 10;
```

Data Profiling: Auditoria Estrutural Antes de Gerar Indicadores

O que é Data Profiling?

É o processo analítico de investigar a estrutura profunda, o conteúdo, as limitações e a qualidade geral dos dados antes de projetar qualquer métrica ou gráfico comercial.

Alerta de Risco para Decisões:

Um dashboard visualmente primoroso e interativo ainda levará a diretoria a decisões desastrosas se a base de dados contiver problemas críticos de integridade ou qualidade.

Perguntas Analíticas & Exemplos de SQL

1. Quantidade total de linhas?

```
SELECT COUNT(*) FROM vendas;
```

2. Qual é a janela temporal disponível?

```
SELECT MIN(Data), MAX(Data) FROM vendas;
```

3. Quais categorias e estados distintos?

```
SELECT DISTINCT Categoria FROM vendas;
```

4. Existem produtos com valor nulo?

```
SELECT * FROM vendas WHERE Produto IS NULL;
```

5. Qual a taxa de preenchimento?

```
SELECT COUNT(*), COUNT(Produto) FROM vendas;
```

SQL para Análise: Filtros Estruturados e Agregações de Negócio

Filtros Analíticos com WHERE e ORDER BY

- **Amostragem por Estado:**

```
SELECT * FROM vendas WHERE Estado = 'SP';
```

- **Filtro Composto Multicritério:**

```
SELECT * FROM vendas WHERE Estado = 'SP' AND Receita > 5000;
```

- **Ordenação Descendente (Top Maiores):**

```
SELECT * FROM vendas ORDER BY Receita DESC;
```

Sempre transforme linhas de código SQL em respostas a perguntas reais do negócio: 'Quais foram as maiores vendas de SP?' ou 'Quem são nossos principais clientes em receita?'

Agregações e Métricas Principais

As funções SUM(), AVG(), COUNT(), MIN() e MAX() consolidam registros de transação bruta em indicadores estratégicos:

Faturamento Bruto (Receita Total):

```
SELECT SUM(Receita) AS receita_total FROM vendas;
```

Rentabilidade Bruta (Lucro Total):

```
SELECT SUM(Lucro) AS lucro_total FROM vendas;
```

Média de Compra (Ticket Médio):

```
SELECT AVG(Receita) AS ticket_medio FROM vendas;
```

Transformando Registros: GROUP BY e CASE WHEN na Prática

GROUP BY: Consolidando Visões

O GROUP BY agrupa transações individuais por dimensões comerciais de interesse para permitir comparações categóricas rápidas:

Receita Consolidada por Categoria:

```
SELECT Categoria, SUM(Receita) AS Receita_Total  
FROM vendas GROUP BY Categoria;
```

Receita por Estado (Top performance):

```
SELECT Estado, SUM(Receita) AS Receita_Total  
FROM vendas GROUP BY Estado ORDER BY  
Receita_Total DESC;
```

CASE WHEN: Criando Novas Categorias

Permite classificar transações de forma lógica e personalizada em tempo de execução, sem alterar a tabela original no banco de dados:

Classificação de Transações por Faixa de Receita:

```
SELECT Produto, Receita,
```

Dica: Você também pode agrupar diretamente pela classificação gerada para saber a quantidade exata de transações em cada faixa!

Critérios Visuais: Como Escolher o Gráfico Adequado

Elemento Visual	Aplicação Principal e Finalidade	Exemplo Prático no Databricks
Gráfico de Barras	Comparação de volumes entre categorias discretas e sem ordem temporal definida.	Faturamento consolidado segmentado por Categoria ou por Estado.
Gráfico de Linha	Evolução de métricas ao longo de períodos contínuos de tempo (tendências).	Evolução do faturamento total agrupado por Ano e Mês (YEAR, MONTH).
Gráfico de Pizza	Análise de participação ou distribuição percentual (limite de 3-4 fatias máximas).	Visualização da distribuição de faturamento por Canal de Venda.
Tabela Estruturada	Exibição de valores exatos, detalhamento de dados brutos ou ordenações complexas.	Inspecionar ranking ordenado com TOP 10 maiores vendedores da empresa.
KPI Dashboard Card	Destaque e centralização imediata dos principais indicadores e objetivos do negócio.	Destaque centralizado no topo: Receita, Lucro Total e Margem de Lucro %.

Prática: Construindo o Mini Dashboard Comercial

O Desafio da Diretoria

Imagine que você é o analista de dados da empresa e recebeu a base bruta. A diretoria solicitou uma visualização concisa que responda de forma visual a 9 objetivos críticos:

1. Receita Bruta Total
2. Rentabilidade Bruta (Lucro)
3. Margem de Lucro Percentual (%)
4. Volume Total Vendido
5. Receita por Categoria Comercial
6. Receita Distribuída por Estado (UF)
7. Evolução Temporal do Faturamento
8. Performance: Top Vendedores
9. Participação por Canal de Venda

A Regra de Ouro do Analista

Antes de clicar para gerar qualquer gráfico no Databricks, o analista de dados DEVE registrar por escrito qual pergunta de negócio aquela visualização pretende responder.

Exemplo Prático Exigido:

- **Pergunta Comercial:** Quais categorias geram maior receita para a nossa empresa?
- **Consulta SQL:** `SELECT Categoria, SUM(Receita) AS Receita_Total
FROM vendas GROUP BY Categoria ORDER BY Receita_Total DESC;`
- **Visualização Recomendada:** Gráfico de Barras Horizontais.

Fechamento da Aula: O Fim é uma Decisão Facilitada

Desafio de Fixação Final

"Qual combinação de Estado + Categoria de Produto gera a maior receita consolidada para a empresa?"

A Grande Mensagem de Fechamento

"O objetivo final de um dashboard de dados não é mostrar informações bonitas ou complexas. É facilitar e apoiar uma decisão estratégica ágil."

Sugestão para a Próxima Aula (Aula 3):

Avançar para transformações de dados complexas: JOINS entre múltiplas tabelas, Common Table Expressions (CTEs), tratamento avançado de duplicidades, criação de views e introdução ao PySpark.

Fechamento da Aula: O Fim é uma Decisão Facilitada

Gabarito da Consulta SQL de Referência:

```
SELECT Estado, Categoria, SUM(Receita) AS Receita_Total  
FROM vendas  
GROUP BY Estado, Categoria  
ORDER BY Receita_Total DESC  
LIMIT 1;
```